Rapport hors séance - TP1

Module : Linked Open Data

Groupe : *[01]*
Étudiants : *MOUKHALISS Hiba*
Date : *19/04/2026*

Introduction

Ce rapport présente une étude préparatoire à la publication en *Linked Open Data* (LOD) du jeu de données « Établissements de l'enseignement supérieur universitaire public au Maroc (2024-2025) », produit par le MESRSI et diffusé sur le portail data.gov.ma. L'objectif est d'évaluer dans quelle mesure ce fichier tabulaire peut être transformé en ressources interconnectables. Nous nous concentrons sur trois types d'entités : **université**, **ville** et **établissement**. Le problème d'ingénierie des données identifié repose sur l'absence d'identifiants persistants, la variabilité orthographique des noms et l'absence de liens explicites vers des référentiels externes, ce qui nécessite une phase de normalisation et d'alignement préalable à toute modélisation RDF.

Types d'entités étudiés

Nous retenons trois entités centrales :

- **Université** (ex : « Université Mohammed V ») : point d'ancrage hiérarchique regroupant 12 entités. Facile à apparier grâce à des noms officiels stables et des sites institutionnels.
- **Ville** (ex : « Rabat ») : indispensable pour la géolocalisation, les filtres régionaux et la désambiguïsation des établissements homonymes.
- **Établissement** (ex : « ENSIAS ») : unité principale du dataset (165 records). Nécessite une stratégie d'identification robuste car les noms sont longs et les sigles parfois ambigus.

Les champs mobilisés pour l'appariement sont `institution_name`, `city`, `website` et `institution_type`. Le `website` est particulièrement utile comme indice de confiance élevé, à condition qu'il soit officiel et stable.

Benchmark des référentiels externes

Nous comparons quatre référentiels selon cinq critères : couverture des entités marocaines, qualité/persistance des identifiants, richesse sémantique, facilité d'appariement et maturité LOD.

Conclusion du benchmark : *Wikidata* est le plus adapté pour les universités et établissements

Référentiel	Intérêt principal	Limites observées	Couverture Maroc
Wikidata	Identifiants stables (Qxxxx), multilingue, liens vers DBpedia/GeoNames	Couverture inégale pour les petites écoles	Élevée pour les universités
GeoNames	Hiérarchie administrative claire, coordonnées GPS, IDs numériques	Ne couvre pas les organisations éducatives	Très élevée (villes/régions)
ROR	Identifiants persistants dédiés à la recherche internationale, API simple	Peu d'établissements marocains référencés actuellement	Moyenne (universités majeures)
data.gov.ma	Référentiel national, contexte administratif local	Pas d'URI persistantes documentées pour les entités	Variable selon les jeux

Table 1 – Synthèse du benchmark des référentiels externes.

connus ; *GeoNames* est incontournable pour les villes. *ROR* constitue un complément stratégique pour l'interopérabilité recherche.

Cas d'appariement manuel

Nous avons documenté six cas représentatifs. La décision repose sur la convergence de trois indices : nom exact, localisation et site officiel.

Table 3 – Échantillon de cas d'appariement manuel.

Ambiguïtés : Les entités génériques (« Faculté des Sciences ») nécessitent systématiquement la ville et l'université de rattachement pour éviter les faux positifs.

Plan de normalisation et d'identification

Avant toute transformation RDF, les règles suivantes seront appliquées :

— **Nettoyage textuel** : suppression des accents pour le *matching*, conversion en minuscules,

extraction systématique du type d'établissement via expressions régulières.

— **Normalisation des URLs** : forcer `https://`, supprimer le préfixe `www`, vérifier l'unicité.
— **Nomenclature contrôlée** : mapper `institution_type` vers un vocabulaire restreint {university, faculty, engineering_school, research_institute, public_school}.
— **Construction d'URI locales** : schéma préconisé `https://data.gov.ma/id/{type}/{slug}`. Exemple : `https://data.gov.ma/id/etablissement/um5-engineering-ensias`.

Priorité d'identification : (1) Universités (alignement externe immédiat), (2) Villes (GeoNames), (3) Établissements (URI locale transitoire en attendant un référencement ROR/Wikidata).

Analyse des risques

— **Faux appariements** : Risque modéré sur les établissements à noms génériques. Contre-mesure : validation croisée par `website` + `city` + `university`.
— **Désambiguïsation géographique** : L'absence de coordonnées GPS dans le dataset source empêche la validation automatique par proximité spatiale.
— **Limites des référentiels** : ROR et Wikidata sous-représentent encore les petites écoles marocaines. Nécessité de maintenir des URI locales avec un mécanisme de *versioning*.
— **Instabilité des sites web** : Utiliser `website` comme clé candidate est risqué si le domaine change. Recommandation : ne pas l'utiliser comme URI permanente, mais comme `foaf:homepage`.

Difficultés rencontrées

Le principal obstacle technique est l'absence d'identifiant persistant dans le fichier source (`record_id` n'est qu'un numéro de ligne technique). Les variations orthographiques (« Rabat »vs « RABAT ») et les abréviations non standardisées (« EHTP », « INPT ») compliquent l'automatisation de l'alignement. Enfin, la couverture inégale des référentiels externes impose un travail manuel de curation pour environ 20% des établissements, ce qui limite la scalabilité immédiate du pipeline LOD.

Conclusion

Cette étude préparatoire démontre que le jeu de données du MESRSI constitue une base solide pour une future publication en LOD, à condition d'appliquer une normalisation stricte des champs textuels et d'adopter une stratégie d'identification hybride (externes quand possible, locales sinon). La documentation explicite des règles de génération d'URI et la curation des cas ambigus garantiront la fiabilité du graphe. Ce travail structure directement le TP2 : les entités identifiées, les liens validés et les schémas de normalisation définis ici permettront une modélisation RDF fluide et la rédaction de requêtes SPARQL pertinentes dès la prochaine séance.

Annexes

- Tableau complet des 165 établissements et de leurs métadonnées (disponible dans `higher_education_sample.csv`)
- Schéma conceptuel Mermaid des entités et relations (voir `carte_des_liens.md`)
- Script de nettoyage Python (regex de normalisation + mapping GeoNames)